




飞桨多模态大模型开发套件 PaddleMIX 2.1版本发布

主讲人：吕文玉



PP-InsCapTagger

背景:


模型规模是提升模型性能的关键因素之一。

在有限的计算资源预算下，用更少的训练步数训练一个更大的模型，往往比用更多的步数训练一个较小的模型效果更佳。



动机:

通过选取少量的高质量的数据集来提升训练效率（如有需求也可通过增加模型参数进一步提升模型效果）



问题:



- ✓ 高质量的定义
- ✓ 选取数据的策略



方案:


- ✓ 能力标签模型
- ✓ 基于信息密度的数据过滤方案

PP-InsCapTagger

什么是能力标签？

定义：


在多模态任务中，每条数据都可以抽象出**一种或多种能力**，在训练时，模型会从这些数据中学习并增强自身**对应的能力**



PP-InsCapTagger

获取能力标签数据方法

方案1: Caption模型 + 纯文大模型



方案2: 多模态大模型



1 你是一个智能标签系统，主要任务是为输入的指令意图提供恰当且有用的粗粒度标签，以便为人工智能助手提供清晰的方向。在生成这些标签时，请确保遵循以下指导原则：

2 1. 深入理解指令：首先，仔细分析输入的指令，明确用户想要完成的任务和所需的信息。

3 2. 关注图片内容：关注图片描述中的关键元素，如物体、颜色、场景等，并理解它们之间的关系。

4 3. 结合问题背景：将问题与图片内容相结合，理解用户的查询意图和他们希望从图片中获取的信息。

5 4. 识别关键操作：分析完成指令可能涉及的操作和步骤，例如计数、识别、比较等，以确定所需的标签。

6 5. 提供合适的标签：基于上述分析，提供能够准确反映指令意图的粗粒度标签。标签应简洁明了，能够明确指导后续操作。

7

8 * 响应格式：

9 标签：[标签列表]

10 解释：[依次解释添加每个标签的理由]

11

12 * 示例：

13 图片描述：一个房间里摆放着几个不同颜色的苹果。

14 问题：请计算图片中红色苹果的数量。

15 响应：

16 标签：['物品计数'、'颜色识别']

17 解释：指令要求计算红色苹果的数量，因此涉及物品计数和颜色识别两个关键操作。这两个标签能够清晰地表达指令的主要意图。

18

19 请根据上述指导原则，为下面给定的图片描述和问题提供合适的响应。

20 图片描述：{}

21 问题：{}

Prompt示例

基础模型-LLaVA简介

预训练



- ✓ 特征对齐
- ✓ 数据为图文对
- ✓ 冻结视觉编码器和语言模型

指令微调

- ✓ 端到端任务
- ✓ 冻结视觉编码器
- ✓ 指令跟随的QA数据

升级点

- ✓ 更强的基座模型 (e.g. Vicuna、Llama 3、Qwen系列)
- ✓ 质量更高的数据 (e.g. 真实场景数据、闭源商业模型生成)
- ✓ 有效的训练策略 (e.g. 图像分辨率、interleave数据)
- ✓ 更多的模型能力 (e.g. 多图理解能力、视频理解能力)
- ✓ 更现代化的结构 (e.g. 有效的Connector)



PP-InsCapTagger

能力标签模型训练

lora微调

```
python paddlemix/tools/supervised_finetune.py
paddlemix/config/llava/v1_5/lora_sft_argument.json
```

full参数微调

```
python paddlemix/tools/supervised_finetune.py
paddlemix/config/llava/v1_5/sft_argument.json
```

多卡训练

```
python -m paddle.distributed.launch \
--log_dir output/logs \
--master $master:$port \
--nnodes $nnodes \
--rank $rank \
--run_mode=collective \
${script:-paddlemix/tools/supervised_finetune.py}
```

	微调阶段
目标	标签专家模型
数据集	5w
初始化参数	LLaVA 1.6 stage 2
ViT Trainable	✗
LLM Trainable	✓
Projection Layer Trainable	✓
Epochs	1
Batch size	128
Learning rate	2e-5
Optimizer	AdamW
DeepSpeed stage	3

基于信息密度的数据过滤方案

定义:


具有能力标签多的样本其包含的信息密度高于能力标签少的样本

实现:

- ✓ 确定出能够覆盖80%数据的单条数据的标签数量M
- ✓ 在数据集标签集合中选出标签数量占比前0.7%的标签作为一个筛选集合R
- ✓ 样本的数据标签数量小于M，且该条数据的所有标签均在集合R中，则删除该条数据，否则保留该条数据

复杂样本

高频标签



基于信息密度的数据过滤方案

实验设置

	Stage 1: 特征对齐的预训练	Stage 2: 端到端微调 (Visual instruction tuning)	Our: 使用PP-InsCapTagger基于信息密度过滤数据后重训Stage 2
目标	对齐Vision & Text	让模型适应视觉问答任务	让模型适应视觉问答任务（提高训练效率）
数据集	558K	665K	313K (基于信息密度过滤llava_sft_665k)
ViT Trainable	✗	✗	✗
LLM Trainable	✗	✓	✓
Projection Layer Trainable	✓	✓	✓
Epochs	1	1	1
Batch size	256	128	128
Learning rate	1e-3	2e-5	2e-5
Optimizer	AdamW	AdamW	AdamW
DeepSpeed stage	2	3	3
训练时长	-	20 hours for LLaVA-v1.5-7B on 8x A100 (80G)	10 hours for LLaVA-v1.5-7B on 8x A100 (80G)

基于信息密度的数据过滤方案

实验结论


Model	ScienceQA	TextVQA	VQAv2	GQA	mmmu	mme
llava-1.5-7b (origin)	66.8	58.2	78.5	62	-	-
llava-1.5-7b (rerun)	69.01	57.6	79	62.95	36.89	1521 323
llava-1.5-7b (random 47%)	67.31	55.6	76.89	61.01	34.67	1421 286
llava-1.5-7b (our 47%)	70.24(+2.93)	57.12(+1.52)	78.32(+1.43)	62.14(+1.13)	37.11(+2.44)	1476(+55) 338(+52)

基于信息密度的数据过滤方案（PP-InsCapTagger和数据选择算法）采样出的数据子集（约占全量的47%）优于随机采样，最终可提升50%的训练效率。

PP-InsCaptagger总结

原始数据

数据A



Q: What animal is in the image

A: The image feature a dog

Q: What color are the dog's eyes?

A: he dog has blue eyes

数据B



Q: How many people are snowboarding

A: There are two people snowboarding


Q: What is the activity the two people are doing

A: The two people are engaged in snowboarding,

Q: Are the two snowboarders close to each other

A: The two snowboarders are riding side by side

PP-InsCaptagger



标签集

动物识别

颜色判断

物品计数

活动识别

距离判断

基于信息密度过滤

标签数量少
标签高频

标签数量多
标签低频

